# Entregable D: Algoritmos básicos de aprendizaje

## Laura Rodriguez Navas

#### Febrero 2020

#### Los Datos

El fichero glass.data incluye el estudio de la clasificación de los tipos de vidrio con 6 variables explicativas. El estudio fue motivado por una investigación criminológica. En la escena de un crimen, el vidrio que queda puede usarse como evidencia . . . ¡si se identifica correctamente!

Las variables que se guardaron son:

- 1. Id number: 1 to 214
- 2. RI: refractive index
- 3. Na: Sodium (unit measurement: weight percent in corresponding oxide, as are attributes 4-10)
- 4. Mg: Magnesium
- 5. Al: Aluminum
- 6. Si: Silicon
- 7. K: Potassium
- 8. Ca: Calcium
- 9. Ba: Barium
- 10. Fe: Iron
- 11. Type of glass: (class attribute)
- 1 building windows float processed
- 2 building windows non float processed
- $\bullet$  3 vehicle\_windows\_float\_processed
- 4 vehicle\_windows\_non\_float\_processed (none in this database)

## The following object is masked from 'package:stats':

- 5 containers
- 6 tableware
- 7 headlamps

Primero debemos cargar los datos como un data frame, nombrado glass, y le damos nombres a las columnas.

```
library(caret)
```

##

```
## Loading required package: lattice
## Loading required package: ggplot2
library(rJava)
library(RWeka)
library(ggplot2)
library(ROCR)

## Loading required package: gplots
##
## Attaching package: 'gplots'
```

```
## lowess
```

```
glass <- read.table("glass.data", header = FALSE, sep = ",")</pre>
names(glass) <- c("Id number", "RI", "Na", "Mg", "Al", "Si", "K", "Ca", "Ba", "Fe",</pre>
                  "Type of glass")
colnames(glass) <- make.names(colnames(glass))</pre>
str(glass)
##
  'data.frame':
                    214 obs. of 11 variables:
##
    $ Id.number
                           1 2 3 4 5 6 7 8 9 10 ...
                    : int
##
    $ RI
                           1.52 1.52 1.52 1.52 1.52 ...
##
    $ Na
                    : num
                           13.6 13.9 13.5 13.2 13.3 ...
##
   $ Mg
                           4.49 3.6 3.55 3.69 3.62 3.61 3.6 3.61 3.58 3.6 ...
                    : num
    $ Al
                           1.1 1.36 1.54 1.29 1.24 1.62 1.14 1.05 1.37 1.36 ...
##
                    : num
##
    $ Si
                           71.8 72.7 73 72.6 73.1 ...
                    : num
##
    $ K
                          0.06 0.48 0.39 0.57 0.55 0.64 0.58 0.57 0.56 0.57 ...
                    : num
##
   $ Ca
                          8.75 7.83 7.78 8.22 8.07 8.07 8.17 8.24 8.3 8.4 ...
##
    $ Ba
                           0 0 0 0 0 0 0 0 0 0 ...
                    : num
                    : num 0 0 0 0 0 0.26 0 0 0 0.11 ...
##
    $ Fe
    $ Type.of.glass: int 1 1 1 1 1 1 1 1 1 ...
```

Observamos que la primera columna (cuyo nombre es "Id number") es redundante (denota el identidficador de cada instancia), por lo que se borrará. También le cambiaremos el nombre a la última columna (cuyo nombre es "Type of glass") para que se entienda mejor que respresenta a la variable clase. El resto son las variables predictoras.

```
glass <- subset(glass, select = -Id.number)
colnames(glass)[10] <- "Class"
head(glass, 10)</pre>
```

```
##
           RΙ
                           Al
                                  Si
                                        K
                                            Ca Ba
                      Mg
     1.52101 13.64 4.49 1.10 71.78 0.06 8.75
                                                0 0.00
                                                           1
     1.51761 13.89 3.60 1.36 72.73 0.48 7.83
     1.51618 13.53 3.55 1.54 72.99 0.39 7.78
                                                0 0.00
                                                           1
     1.51766 13.21 3.69 1.29 72.61 0.57 8.22
                                                           1
     1.51742 13.27 3.62 1.24 73.08 0.55 8.07
                                                0 0.00
                                                           1
     1.51596 12.79 3.61 1.62 72.97 0.64 8.07
                                                           1
     1.51743 13.30 3.60 1.14 73.09 0.58 8.17
                                                0 0.00
                                                           1
## 8 1.51756 13.15 3.61 1.05 73.24 0.57 8.24
                                                           1
## 9 1.51918 14.04 3.58 1.37 72.08 0.56 8.30
                                                0 0.00
                                                           1
## 10 1.51755 13.00 3.60 1.36 72.99 0.57 8.40
                                                           1
```

Aunque a primera vista los datos parecen que estan ordenados por la columna Class, los ordenamos. Y miramos que no existan valores codificados como NA.

```
glass <- glass[order(glass$Class), ]
any(is.na(glass))</pre>
```

#### ## [1] FALSE

Como se ha comentado anteriormente, la columna Class representa la variabla clase. Pero en este caso contamos con 6 variables explicativas. Para poder generar una representación binária seleccionaremos solo los elementos de la columna Class con los valores  $\{1, 2\}$ , les cambiaremos el nombre  $\{1 = \text{positive}, 2 = \text{negative}\}$  y factorizaremos la varible clase.

```
glass <- subset(glass , glass$Class < 3)
for (i in 1:146) {
  if (glass$Class[i] == 1){</pre>
```

```
glass$Class[i] <- 'positive'</pre>
 }
 else {
   glass$Class[i] <- 'negative'</pre>
 }
glass[,10]=as.factor(glass[,10])
str(glass)
## 'data.frame':
                   146 obs. of 10 variables:
          : num 1.52 1.52 1.52 1.52 1.52 ...
## $ RI
## $ Na
         : num 13.6 13.9 13.5 13.2 13.3 ...
          : num 4.49 3.6 3.55 3.69 3.62 3.61 3.6 3.61 3.58 3.6 ...
## $ Mg
## $ Al
          : num 1.1 1.36 1.54 1.29 1.24 1.62 1.14 1.05 1.37 1.36 ...
## $ Si
          : num 71.8 72.7 73 72.6 73.1 ...
## $ K
          : num 0.06 0.48 0.39 0.57 0.55 0.64 0.58 0.57 0.56 0.57 ...
## $ Ca
          : num 8.75 7.83 7.78 8.22 8.07 8.07 8.17 8.24 8.3 8.4 ...
          : num 0000000000...
## $ Ba
          : num 0 0 0 0 0 0.26 0 0 0 0.11 ...
## $ Fe
## $ Class: Factor w/ 2 levels "negative", "positive": 2 2 2 2 2 2 2 2 2 ...
```

# División de los datos en muestra de entrenamiento y de test

Tomaremos una muestra del 70% del conjunto de datos como entrenamiento, el 30% del mismo como un conjunto de prueba.

La validación cruzada 5 veces con muestreo estratificado se utiliza para dividir el conjunto de datos en conjuntos de entrenamiento y prueba.

```
set.seed(123)
inTraining <- createDataPartition(glass$Class, p = .7, list = FALSE)
training <- glass[ inTraining,]</pre>
testing <- glass[-inTraining,]</pre>
fitControl <- trainControl(method = "cv",</pre>
                          number = 5,
                          classProbs = FALSE)
str(training)
## 'data.frame':
                   103 obs. of 10 variables:
## $ RI
                1.52 1.52 1.52 1.52 1.52 ...
          : num
##
   $ Na
                13.9 13.5 13.2 13.3 12.8 ...
          : num
## $ Mg
          : num 3.6 3.55 3.69 3.62 3.61 3.6 3.61 3.6 3.66 3.43 ...
          : num 1.36 1.54 1.29 1.24 1.62 1.14 1.05 1.36 1.27 1.4 ...
## $ Al
## $ Si
          : num 72.7 73 72.6 73.1 73 ...
          : num 0.48 0.39 0.57 0.55 0.64 0.58 0.57 0.57 0.6 0.69 ...
   $ K
## $ Ca
         : num 7.83 7.78 8.22 8.07 8.07 8.17 8.24 8.4 8.56 8.05 ...
## $ Ba
          : num 0000000000...
                 0 0 0 0 0.26 0 0 0.11 0 0.24 ...
##
   $ Fe
           : num
## $ Class: Factor w/ 2 levels "negative", "positive": 2 2 2 2 2 2 2 2 2 2 ...
str(testing)
                   43 obs. of 10 variables:
## 'data.frame':
## $ RI
          : num 1.52 1.52 1.52 1.52 1.52 ...
## $ Na
          : num 13.6 14 12.7 13.9 13 ...
```

: num 4.49 3.58 3.46 3.73 3.54 3.48 3.48 3.45 3.53 3.48 ...

## \$ Mg

```
## $ Al : num 1.1 1.37 1.56 1.18 1.21 1.41 1.33 1.21 1.32 1.35 ...
## $ Si : num 71.8 72.1 73.2 72.1 73 ...
## $ K : num 0.06 0.56 0.67 0.06 0.65 0.59 0.56 0.56 0.51 0.64 ...
## $ Ca : num 8.75 8.3 8.09 8.89 8.53 8.43 8.43 8.57 8.78 8.68 ...
## $ Ba : num 0 0 0 0 0 0 0 0 0 0 0 0 0 0 ...
## $ Fe : num 0 0 0.24 0 0 0 0 0 0 0 ...
## $ Class: Factor w/ 2 levels "negative", "positive": 2 2 2 2 2 2 2 2 2 2 ...
```

#### Entrenamiento de los modelos

Se utilizarán 3 algoritmos de clasificación diferentes para predecir. Los modelos son: OneR, kNN y Multilayer Perceptrón.

```
1. OneR.
oner <- train(Class ~ ., data = training,
               method = "OneR",
               trControl = fitControl)
oner
## Single Rule Classification
##
## 103 samples
##
    9 predictor
     2 classes: 'negative', 'positive'
##
## No pre-processing
## Resampling: Cross-Validated (5 fold)
## Summary of sample sizes: 83, 82, 82, 82, 83
## Resampling results:
##
##
     Accuracy
                 Kappa
     0.8452381 0.688327
onerPredict <- predict(oner, newdata = testing)</pre>
cm_oner <- confusionMatrix(onerPredict, testing$Class)</pre>
onerPredictProb <- predict(oner, newdata = testing, type = "prob")</pre>
onerPred <- prediction(onerPredictProb$positive, testing$Class)</pre>
onerPerf <- performance(onerPred, "tpr", "fpr")</pre>
  2. kNN con k=1, k=3 y con peso por distancia (tres configuraciones en total).
grid_knn <- expand.grid(k = seq(1, 3))</pre>
knn <- train(Class ~ ., data = training,</pre>
               method = "knn",
               trControl = fitControl,
               tuneGrid = grid_knn)
## k-Nearest Neighbors
##
## 103 samples
##
     9 predictor
##
     2 classes: 'negative', 'positive'
##
```

```
## No pre-processing
## Resampling: Cross-Validated (5 fold)
## Summary of sample sizes: 83, 82, 82, 82, 83
## Resampling results across tuning parameters:
##
    k Accuracy
                   Kappa
     1 0.7852381 0.5701258
##
     2 0.7657143 0.5325650
##
##
     3 0.7361905 0.4718654
##
## Accuracy was used to select the optimal model using the largest value.
## The final value used for the model was k = 1.
knnPredict <- predict(knn, newdata = testing)</pre>
cm_knn <- confusionMatrix(knnPredict, testing$Class)</pre>
knnPredictProb <- predict(knn, newdata = testing, type = "prob")</pre>
knnPred <- prediction(knnPredictProb$positive, testing$Class)
knnPerf <- performance(knnPred, "tpr", "fpr")</pre>
  3. Multilayer Perceptrón con una sola capa oculta y 3, 5, y 7 unidades ocultas en la misma (tres
    configuraciones en total).
grid_mlp = expand.grid(layer1 = 3,
                        layer2 = 5,
                        layer3 = 7)
mlp <- train(Class ~., data = training,</pre>
             method = "mlpML",
             trControl = fitControl,
             tuneGrid = grid_mlp)
mlp
## Multi-Layer Perceptron, with multiple layers
##
## 103 samples
##
     9 predictor
     2 classes: 'negative', 'positive'
##
##
## No pre-processing
## Resampling: Cross-Validated (5 fold)
## Summary of sample sizes: 82, 82, 82, 83, 83
## Resampling results:
##
##
     Accuracy
                Kappa
##
     0.5242857 0
##
## Tuning parameter 'layer1' was held constant at a value of 3
## Tuning
## parameter 'layer2' was held constant at a value of 5
## Tuning parameter
## 'layer3' was held constant at a value of 7
mlpPredict <- predict(mlp, newdata = testing)</pre>
cm_mlp <- confusionMatrix(mlpPredict,testing$Class)</pre>
```

```
mlpPredictProb <- predict(mlp, newdata = testing, type = "prob")
mlpPred <- prediction(mlpPredictProb$positive, testing$Class)
mlpPerf <- performance(mlpPred, "tpr", "fpr")</pre>
```

### Resultados

# **CURVAS ROC**

