Universidad
Internacional
Menéndez Pelayo

Máster Universitario en Investigación en Inteligencia Artificial

Curso 2020-2021

Recuperación y extracción de información, grafos y redes sociales

Práctica Bloque II: Recuperación de información y minería de texto

21 de abril de 2021

Laura Rodríguez Navas
DNI: 43630508Z
e-mail: rodrigueznavas@posgrado.uimp.es

Índice

1. Resumen

En esta práctica se ha implementado un rastreador web (crawler) en Python (ver Sección 2), que se complementa con un proceso de agrupamiento (ver Sección 3), también implementado en Python, de la información extraída por el rastreador web. En este documento se describe el desarrollo paso a paso, que se puede descargar de [1].

2. Rastreador web

En esta sección se describe como se ha implementado el rastreador web (crawler) en Python usando la librería Scrapy, y para empezar este desarrollo se ejecutó el siguiente comando:

```
$ scrapy startproject books
```

Este comando crea un proyecto Scrapy en el directorio books, siguiendo la estructura por defecto común para todo proyecto Scrapy. El comando también crea el fichero *scrapy.cfg*, que contiene el nombre del módulo en Python que define la configuración del proyecto books. El proyecto Scrapy de la práctica lo he llamado books, porqué se rastrea y recupera información de un catálogo de libros, que podemos encontrar en el siguiente enlace a la página web: http://books.toscrape.com.

Una vez se ha creado el proyecto con el comando anterior, se deben que definir los ítems de cada libro que se quieran extraer del catálogo web. En este caso los ítems que se extraen son: el título, la categoría, la descripción, el precio y la valoración de cada libro. Para que el rastreador lo tenga en cuenta, se tiene que modificar el fichero *books/items.py*, para incluir los cinco ítems que se quieren extraer. A continuación, podemos ver los ítems añadidos en el fichero *items.py*:

```
class BooksItem(scrapy.Item):
  # define the fields for your item here like:
  # name = scrapy.Field()
  title = scrapy.Field()
  category = scrapy.Field()
  description = scrapy.Field()
  price = scrapy.Field()
  rating = scrapy.Field()
```

El siguiente paso es describir la manera de extraer la información de estos ítems. Para ello, se utilizan reglas de expresión XPath y CSS. Por ejemplo, si nos fijamos en el código HTML de uno de los libros que se van rastrear (ver Figura 1), veremos que el título del libro es fácil de extraer con la siguiente regla de expresión CSS: **"h1 ::text"**. Por otro lado, cuando la extracción de información se complica un poco más, se usan reglas de expresión XPath. Por ejemplo, para extraer las descripciones de todos los libros se usa la regla de expresión: **"//div[@id='product_description']/following-sibling::p/text()"**.

En este documento no se describen todas las reglas de expresión que se han desarrollado, pero se pueden consultar en [1], concretamente en el fichero *books/spiders/books_toscrape.py*. Este fichero es la araña o más comúnmente llamada en inglés *spider*, que contiene todas las reglas de expresión de cada uno de los ítems de *items.py*, para definir como se va a rastrear y cómo se va a extraer la información del catálogo de libros en la web.

Definición 1. *Las arañas son clases en Python que definen cómo se rastrea una página web determinada (o un grupo de páginas web), incluido cómo realizar el rastreo y cómo extraer la información deseada. En otras palabras, las arañas son el lugar donde se define el comportamiento personalizado para rastrear y analizar las páginas web.*

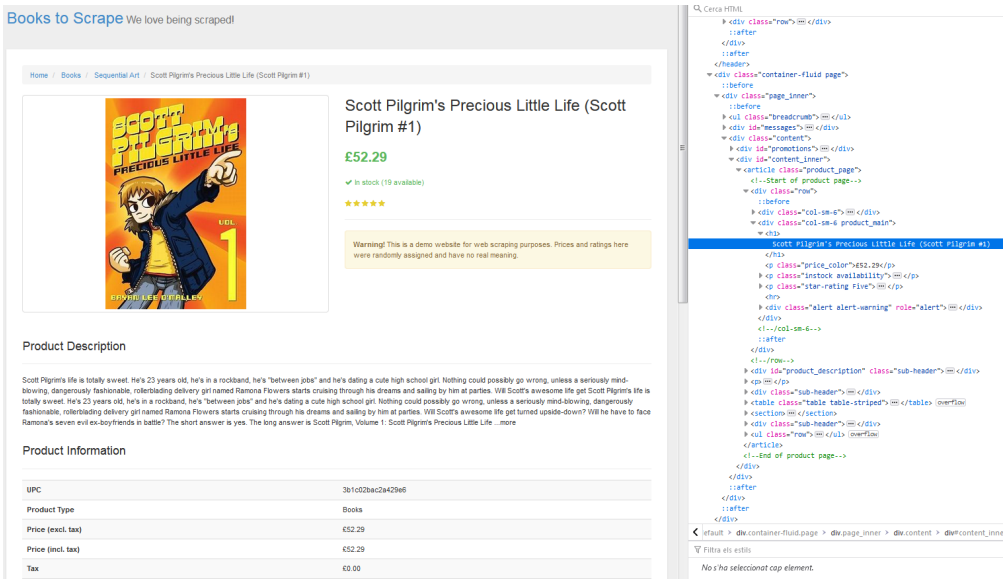

Figura 1: Ejemplo de libro a rastrear.

En las arañas también se tienen que especificar las solicitudes iniciales de todas las URLs a rastrear y crear una función de devolución de llamada (*parse*), a la que se llamará para generar los ítems de respuesta de esas solicitudes. Por último, la información devuelta por las arañas, normalmente se conserva en una base de datos o se escribe en un archivo. En el caso de la práctica, la información de los ítems: título, categoría, descripción, precio y valoración de cada libro, que son devueltos por la araña *books.toscrape*, se guardan en el archivo *books.json*.

La araña desarrollada en esta práctica (*books.toscrape*), que procesa todas las URLs descubiertas de http://books.toscrape.com, utilizando la función *parse*, que a su vez llama a la función *parse_book_page* donde se definen todas las reglas de expresión, se muestra a continuación:

```
class BooksToscrapeSpider(scrapy.Spider):
  name = 'books.toscrape'
  allowed_domains = ['books.toscrape.com']
  start_urls = ['http://books.toscrape.com/']

  def parse(self, response):
    for book_url in response.css("article.product_pod > h3 > a ::attr(href)").extract():
      yield scrapy.Request(response.urljoin(book_url), callback=self.parse_book_page)
    next_page = response.css("li.next > a ::attr(href)").extract_first()
    if next_page:
      yield scrapy.Request(response.urljoin(next_page), callback=self.parse)

  @staticmethod
  def parse_book_page(response):
    item = {}
    product = response.css("div.product_main")
    item["title"] = product.css("h1 ::text").extract_first()
    item['category'] = response.xpath("//ul[@class='breadcrumb']/li[@class='active']/
    preceding-sibling::li[1]/a/text()").extract_first()
    item['description'] = response.xpath("//div[@id='product_description']/following-sibling
    ::p/text()").extract_first()
    price = response.xpath('//th[text()="Price (incl. tax)"]/following-sibling::td/text()').
    extract_first()
    item['price'] = price.replace('£', '')
    rating = response.xpath('//*[contains(@class, "star-rating")]/@class').extract_first()
    item['rating'] = rating.replace('star-rating ', '')
    yield item
```

Apartir de este momento, ya podemos iniciar la araña para que recupere la información de los libros del catálogo web y la escriba en el archivo *books.json*, aunque primero es recomendable modificar el fichero *books/settings.py*, para limitar el acceso de la araña, ya que podemos generar un ataque DDoS. Para no provocar un ataque de este tipo, debemos descomentar la variable DOWNLOAD_DELAY del fichero *books/settings.py* y darle un valor en segundos (p.ej. DOWNLOAD_DELAY = 3).

Finalmente, para iniciar la araña se deben ejecutar los comandos siguientes:

```
$ cd books
$ scrapy crawl books.toscrape -o books.json
```

3. K-Means

En esta sección se describe como se ha desarrollado el proceso de agrupamiento en Python, de los datos recuperados por el rastreador web (crawler) usando la librería scikit-learn [2]. El código llevado a cabo se encuentra en el directorio kmeans de [1], que contiene el algoritmo de agrupación elegido para esta práctica: el algoritmo K-Means. K-Means es un algoritmo no supervisado de clustering, que usualmente se utiliza cuando tenemos un montón de datos sin etiquetar, con el objetivo de encontrar "K" grupos o clústers entre el conjunto de datos. En el caso de la práctica, el algoritmo K-Means agrupará los títulos de los libros del catálogo web en diferentes clústers, y en este caso, el tipo de agrupamiento se denomina *clustering* de textos.

3.1. Datos de entrada

En esta sección se concreta el conjunto de datos que utilizaremos para alimentar el algoritmo K-Means. Para ello, primero se empieza extrayendo la información de los libros almacenada en el fichero *books/books.json*. Segundo, convertimos esta información en un *DataFrame* (ver Definición 2). Además, eliminamos los valores no válidos que pudieran existir en el *DataFrame* y finalmente, este es almacenado en un fichero CSV (*kmeans/books.csv*). Para este procedimiento se ha usado la librería pandas [3]. A continuación, podemos observar las primeras líneas del contenido del *DataFrame* que forman los datos de entrada:

title	category	description	price	rating
Sapiens: A Brief History of Humankind	History	From a renowned historian...	54.23	Five
Sharp Objects	Mystery	WICKED above her hipbone, GIRL...	47.82	Four
Soumission	Fiction	Dans une France assez...	50.10	One
Tipping the Velvet	Historical Fiction	Erotic and absorbing...	53.74	One
A Light in the Attic	Poetry	It's hard to imagine...	51.77	Three

Tabla 1: Conjunto de datos de entrada.

Concretamente, la estructura de datos que se utilizará para alimentar el algoritmo K-Means, está formada por la siguiente lista que contiene los títulos de los libros. Vemos los diez primeros:

```
titles = df["title"].to_list()
print(titles[:10])  # first 10 titles
>> ['Sapiens: A Brief History of Humankind', 'Sharp Objects', 'Soumission', 'Tipping the
    Velvet', 'A Light in the Attic', "It's Only the Himalayas", 'Libertarianism for
    Beginners', 'Mesaerion: The Best Science Fiction Stories 1800-1849', 'Olio', 'Our Band
    Could Be Your Life: Scenes from the American Indie Underground, 1981-1991']
```

Definición 2. *Un DataFrame es una estructura de datos etiquetada bidimensional que acepta diferentes tipos datos de entrada organizados en columnas. Se puede pensar en un DataFrame como una hoja de cálculo o una tabla SQL.*

3.2. Palabras vacías, stemming y tokenización

Esta sección se centra en describir algunas funciones para transformar el conjunto de datos de entrada y así facilitar la ejecución del algoritmo K-Means. Porqué siempre es una buena idea normalizar el conjunto de datos, en este caso de textos, a la hora de realizar un procedimiento de agrupamiento. Hay, por supuesto, muchos tipos de transformaciones, y a continuación se describe la transformación del conjunto de datos que se usa en esta práctica.

Para poder realizar un proceso de transformación de los títulos, se obtienen la lista de palabras vacías en inglés (ver Definición 3), y el Snowball Stemmer con la ayuda de la librería NLTK [4]. Tanto para la lista de las palabras vacías (*stopwords*) o para el Snowball Stemmer se indica el idioma: inglés; ya que los títulos de los libros están inglés.

```
# nltk's English stopwords as variable called 'stopwords'
stopwords = nltk.corpus.stopwords.words('english')
# nltk's SnowballStemmer as variabled 'stemmer'
stemmer = SnowballStemmer("english")
print(stopwords[:10])   # first 10 stopwords
>> ['i', 'me', 'my', 'myself', 'we', 'our', 'ours', 'ourselves', 'you', "you're"]
```

Definición 3. *Las palabras vacías son palabras sin significado como artículos, pronombres, preposiciones, etc. que son filtradas antes o después del procesamiento de datos en lenguaje natural (texto). Por ejemplo: "a", "the", o "in" que no transmiten un significado significativo.*

La obtención de estos dos elementos es necesaria para realizar los procesos de transformación: tokenización y stemming sobre los títulos. Concretamente, el proceso de tokenización divide las cadenas de texto más largas de los títulos en cadenas más pequeñas o tokens. Y el proceso de stemming extrae las raíces de los tokens. El proceso de stemming se realiza porque las raíces de los tokens pueden aparecer repetidamente en diferentes los títulos.

A continuación vemos las funciones *tokenize_and_stem* y *tokenize_only* que se han desarrollado para el proceso de transformación de esta práctica:

```
def tokenize_and_stem(text):
  # first tokenize by sentence, then by word to ensure that punctuation is caught as it's
    own token
  tokens = [word for sent in nltk.sent_tokenize(text) for word in nltk.word_tokenize(sent)]
  filtered_tokens = []
  # filter out any tokens not containing letters (e.g., numeric tokens, raw punctuation)
  for token in tokens:
    if re.search('[a-zA-Z]', token):
      filtered_tokens.append(token)
  stems = [stemmer.stem(t) for t in filtered_tokens]
  return stems

def tokenize_only(text):
  tokens = [word.lower() for sent in nltk.sent_tokenize(text) for word in nltk.word_tokenize
    (sent)]
  filtered_tokens = []
  for token in tokens:
    if re.search('[a-zA-Z]', token):
      filtered_tokens.append(token)
  return filtered_tokens
```

Estas funciones son casi iguales, ya que las dos realizan el mismo proceso de tokenización sobre un texto de entrada, pero no son exactamente iguales porqué la función *tokenize_and_stem*, además, realiza un proceso de stemming. Las funciones se usan para calcular la matriz tf-idf de la siguiente sección y para la visualización de los clústers resultantes de la ejecución del algoritmo K-Means.

3.3. Extracción de características

El clustering es una técnica de aprendizaje automático no-supervisada. Esto implica que no es capaz de establecer la relación entre los atributos de entrada y los resultados ... sencillamente porque no hay resultados. Así que la responsabilidad de identificar qué atributos son relevantes recae sobre nosotros.

Por ejemplo, si estamos usando clustering para segmentar clientes ... seguramente no es buena idea incluir el color de los ojos de los clientes. Esta es una característica posiblemente irrelevante que hará que las distancias entre los puntos multidimensionales que representan cada dato sea menos informativa ... excepto si estamos vendiendo lentillas para cambiar el color de ojos!

En esta sección, se calculará la matriz tf-idf (ver Figura 2). Pero para ello, primero se tienen que calcular las frecuencias de las palabras que contienen los títulos, y el método más popular para hacerlo es el llamado TF-IDF. Este es un acrónimo que significa *Frecuencia de Término – Frecuencia Inversa de Documento* que son los componentes de las puntuaciones resultantes asignadas a cada palabra. Sin entrar en la matemática, TF-IDF son puntuaciones de frecuencia de palabras que tratan de resaltar las palabras que son más interesantes y/o frecuentes. En el caso de la práctica usamos sklearn.feature_extraction.text.TfidfVectorizer.

Figura 2: Ejemplo de matriz tf-idf.

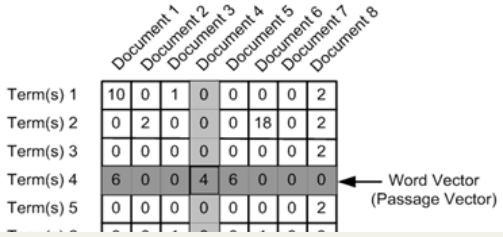


```
tfidf_vectorizer = TfidfVectorizer(stop_words=stopwords, use_idf=True,
  tokenizer=tokenize_and_stem, ngram_range=(1, 3))

# tokenize and build coded vocabulary
tfidf_matrix = tfidf_vectorizer.fit_transform(titles)
print(tfidf_matrix.shape)
>> (998, 7258)
```

La matriz tf-idf está formada por 998 términos y 7258 documentos. También se puede observar el vocabulario (nombrado *terms*) que ha usado *TfidfVectorizer* en la construcción de la matriz:

```
terms = tfidf_vectorizer.get_feature_names()
print(terms[:20])    # first 20 terms
>> ["'d", "'d go", "'d go bernadett", "'m", "'m gone", "'m home", "'m lie", "'m lie tell", "
    's", "'s alic", "'s alic wonderland", "'s astound", "'s astound stori", "'s
    autobiographi", "'s babi", "'s babi ice", "'s berlin", "'s call", "'s call cormoran", "'
    s childhood"]
```

Definición 4. *Un n-grama es una secuencia contigua de n elementos de una muestra determinada de texto o de un discurso. Los elementos pueden ser fonemas, sílabas, letras o palabras según la aplicación. Los n-gramas normalmente se recopilan de un texto.*

Un par de cosas a tener en cuenta sobre los parámetros definidos en la función *TfidfVectorizer*:

- use_idf: habilita la reponderación de frecuencia de documentos inversa.
- ngram_range: define el límite inferior y superior del rango de n-valores para diferentes n-gramas que se extraerán. Ver Definición 4.

3.4. Entrenamiento del algoritmo

Ahora pasamos a la parte divertida. Usando la matriz tf-idf calculada en la sección anterior, se puede ejecutar el algoritmo K-Means utilizando sklearn.cluster.KMeans, para comprender mejor la estructura oculta dentro de

los títulos de los libros del catálogo web. El algoritmo K-Means se inicializa con un número predeterminado de clústeres. Elegí el número 40 como número predeterminado de clústeres, ya que el conjunto de datos de entrada contiene libros que pertenecen al menos a más de dos de las 50 categorías existentes en el conjunto de datos, descartando 10 categorías que solo hacen referencia a un único libro. No se ha utilizado metodo del codo

Algunas técnicas de agrupamiento, tales como K-Means, necesitan que especifiquemos el número de clusters (grupos) que queremos encontrar. No es obvio, a priori, saber qué número de grupos es mejor.

El algoritmo K-Means sigue los siguientes pasos:

- Inicialización: se elige la localización de los centroides de los K grupos aleatoriamente
- Asignación: se asigna cada dato al centroide más cercano
- Actualización: se actualiza la posición del centroide a la media aritmética de las posiciones de los datos asignados al grupo

Los pasos 2 y 3 se siguen iterativamente hasta que no haya más cambios. Vamos a verlo con se ha implementado.

La intención de este ejercicio es agrupar los titulos por las palabras que contienen.

```
num_clusters = 40
km = KMeans(n_clusters=num_clusters)
km.fit(tfidf_matrix)
clusters = km.labels_.tolist()
```

Para analizar los resultados y visualizar los clústeres (*clusters*), ha sido necesario crear dos nuevos dataframes. Uno que contenga los títulos y sus clústeres asignados (*frame*), y otro que contenga las raíces de los títulos con sus palabras asignadas (*vocab_frame*). Para crear el segundo, además, ha sido necesario crear dos nuevos vocabularios: uno que contenga los títulos tokanizados y otro que contenga las raíces de los títulos tokanizados. Para ello se han usado las funciones: *tokenize_and_stem* y *tokenize_only*, ya nombradas anteriormente (ver Sección 3.2).

```
# new df with titles and clusters
frame = pd.DataFrame({'title': titles, 'cluster': clusters}, index=[clusters],
  columns=['title', 'cluster'])
```

```
# new two vocabularies: stemmed and tokenized
totalvocab_stemmed = []
totalvocab_tokenized = []
for i in titles:
  allwords_stemmed = tokenize_and_stem(i)  # for each item in 'titles', tokenize/stem
  totalvocab_stemmed.extend(allwords_stemmed)  # extend the 'totalvocab_stemmed' list

  allwords_tokenized = tokenize_only(i)
  totalvocab_tokenized.extend(allwords_tokenized)

vocab_frame = pd.DataFrame({'words': totalvocab_tokenized}, index=totalvocab_stemmed)
print('There are ' + str(vocab_frame.shape[0]) + ' items in vocab_frame')
>> There are 6371 items in vocab_frame
```

El beneficio de este procedimiento es que proporciona una forma eficiente de buscar una raíz y devolver la palabra que la contiene muy rápidamente. La desventaja es que hay demasiadas raíces, concretamente 6371. Por ejemplo, la raíz 'run' podría estar asociada con 'ran', 'runs', 'running', etc. Aunque para mi propósito de visualización de los clústeres está bien. A continuación podemos observar las primeras líneas del contenido de los dos nuevos dataframes.

Tabla 2: *frame* y *vocab_frame* dataframes.

title	cluster
Sapiens: A Brief History of Humankind	26
Sharp Objects	0
Soumission	12
Tipping the Velvet	12
A Light in the Attic	9

	words
sapien	sapiens
a	a
brief	brief
histori	history
of	of

Finalmente, vemos la función implementada que muestra los resultados por clúster, identificando las n primeras palabras (elegí n=10) que están más cerca de los centroides de cada uno de ellos, y también vemos el resultado de su ejecución (ver Figura 3).

```
# sort cluster centers by proximity to centroid
order_centroids = km.cluster_centers_.argsort()[:, ::-1]

for i in range(num_clusters):
  print("Cluster {} words:".format(i), end='')
  for ind in order_centroids[i, :10]:  # replace 10 with n words per cluster
    print(' {}'.format(vocab_frame.loc[terms[ind].split(' ')].values.tolist()[0][0]),
      end=',')

  print()
  print()

  print("Cluster {} titles:".format(i), end='')
  for title in frame.loc[i]['title'].values.tolist():
    print(' {},'.format(title), end='')

  print()
  print()
```

Podemos ver cada uno de los clústeres las diez palabras más usadas palabras (las palabras que están más cerca a los centroids de cada clúster) y los títulos de cada clúster a las que estan asignadas. Para ver el resultado completo con los 40 clústeres, ver fichero ...

3.5. Evaluación

Finalmente en esta sección, se intentan evaluar los resultados del proceso de agrupamiento de la sección anterior. Decimos que se intentan evaluar, ya que normalmente la evaluación de algoritmos de aprendizaje no supervisados es un poco difícil y requiere de ojo humano, que en mi caso no está muy bien entrenado.

Para la mayoría de los problemas de agrupación en clústeres es usual el uso de dos tipos de métricas: *homogeneity_score* y *silhouette_score*. En el caso de la práctica usamos silhouette_score, que calculará el coeficiente de Silhouette.

El mejor valor del coeficiente de Silhouette es 1, y el peor valor es -1. Los valores cercanos a 0 indican grupos superpuestos. Los valores negativos generalmente indican que se han asignado bastantes clústeres de manera incorrecta.

```
silhouette_coefficient = silhouette_score(tfidf_matrix, labels=km.predict(tfidf_matrix))
print(silhouette_coefficient)
>> 0.02250733514584242
```

Entonces, este valor significa que nuestros clústeres se superponen.

Figura 3: Resultados del proceso de *clustering*.

4. Conclusiones

Hemos visto que el algoritmo de K-Means nos ayuda a crear clusters cuando tenemos grandes grupos de datos sin etiquetar.

Bibliografía

[1] Laura Rodríguez-Navas. Recuperación de información y minería de texto. https://github.com/lrodrin/masterAI/tree/master/A14, 2021.

[2] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.

[3] Jeff Reback, Wes McKinney, jbrockmendel, Joris Van den Bossche, Tom Augspurger, Phillip Cloud, gfyoung, Sinhrks, Simon Hawkins, Matthew Roeschke, Adam Klein, Terji Petersen, Jeff Tratner, Chang She, William Ayd, Shahar Naveh, Marc Garcia, Jeremy Schendel, Andy Hayden, Daniel Saxton, Vytautas Jancauskas, Ali McMaster, Pietro Battiston, Skipper Seabold, patrick, Kaiqi Dong, chris b1, h vetinari, Stephan Hoyer, and Marco Gorelli. pandas-dev/pandas: Pandas 1.1.5, December 2020.

[4] Steven Bird, Ewan Klein, and Edward Loper. *Natural language processing with Python: analyzing text with the natural language toolkit*. "O'Reilly Media, Inc.", 2009.